

# Poszukiwanie minimum wartości funkcji metodą największego spadku w 2D

Wiktoria Zaczek

13.05.2021

## 1 Wstęp

### Minimalizacja funkcji

Inaczej nazywana optymalizacją, jej zadaniem jest poszukiwanie odpowiednio minimum lub maksimum funkcji wielu zmiennych. Chodzi o znalezienie punktu spełniającego warunek

$$\min f(\vec{x}) = f(\vec{x}^*) \Leftrightarrow \bigwedge_{\vec{x} \in R^n} f(\vec{x}^*) < f(\vec{x}), \quad \text{gdzie } \vec{x} = [x_1, x_2, \dots, x_n]^T. \quad (1)$$

### Gradient funkcji

Dla funkcji celu  $f(\vec{x}) \in C^2$ , tj. poszukującej minimum badanej funkcji wejściowej definiuje się funkcję wektorową będącą gradientem funkcji

$$g(\vec{x}) = \nabla f(\vec{x}) = \left[ \frac{\partial f(\vec{x})}{\partial x_1}, \frac{\partial f(\vec{x})}{\partial x_2}, \dots, \frac{\partial f(\vec{x})}{\partial x_n} \right]^T. \quad (2)$$

Należy pamiętać, iż gradient skierowany jest zawsze w stronę narastających wartości.

### Pochodna kierunkowa funkcji celu

Różniczkę zupełną funkcji celu definiuje się jako iloczyn skalarny wektorów

$$df = \frac{\partial f}{\partial x_1} dx_1 + \dots + \frac{\partial f}{\partial x_n} dx_n = \nabla f(\vec{x}) d\vec{x}. \quad (3)$$

Punkty  $\vec{x}$  i  $\vec{x}'$  nazywane są powiązanymi ze sobą, jeżeli wektor  $\vec{u}$  wyznacza kierunek prostej je łączącej, stąd

$$\vec{x}(\lambda) = \vec{x}' + \lambda \vec{u}. \quad (4)$$

Dla bardzo małych zmian wartości  $\lambda$  można uogólnić wzór (4).

$$d\vec{x} = \vec{u} d\lambda \quad (5)$$

Na prostej łączącej ustalone punkty  $\vec{x}$  oraz  $\vec{x}'$  wartość funkcji celu zależna jest od zmiennej  $\lambda$ .

$$F(\lambda) = f(\vec{x}' + \lambda \vec{u}) = f(\vec{x}) \quad (6)$$

Mając na uwadze powyższe powiązania, oblicza się różniczkę zupełną dla funkcji celu zależnej od  $\lambda$

$$dF = df = \nabla^T f(\vec{x}) \vec{u} d\lambda. \quad (7)$$

Finalnie, wyrażenie na **pochodną kierunkową funkcji** celu w punkcie  $\vec{x}$  dla kierunku  $\vec{u}$  jest postaci

$$\frac{dF(\lambda)}{d\lambda} = \left. \frac{df(\vec{x})}{d\lambda} \right|_{\vec{u}} = \nabla^T f(\vec{x}) \vec{u}, \quad (8)$$

jednak korzystając z niej należy ją wyznaczać w każdej iteracji.

### Znajdowanie minimum funkcji przy pomocy pochodnej kierunkowej

Przybliżanie należy rozpocząć z punktu  $\vec{x}_0$  przechodząc przez kolejne punkty  $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_n$  w kierunku spadku wartości funkcji. Pozwala to wyznaczyć ciąg przybliżeń poszukiwanego minimum. Należy przerwać algorytm iteracyjny w momencie, gdy zostanie spełniony jeden z warunków:

1. Norma różnicy wektorów z sąsiednich kroków jest mniejsza od zadanego progu:  $\|\vec{x}^{i+1} - \vec{x}^i\| < \epsilon \nabla f(\vec{x}) = 0$
2. W kolejnych iteracjach wartość normy  $\|\vec{x}^{i+1} - \vec{x}^i\|$  wzrasta, co oznacza brak zbieżności.

### Metoda największego spadku

Korzystając z pochodnej kierunkowej funkcji w punkcie  $x$  dla wektora kierunkowego  $\vec{u}$  o długości równej  $\|\vec{u}\| = 1$

$$\left. \frac{df(\vec{x}')}{d\lambda} \right|_{\vec{u}} = \frac{dF(0)}{d\lambda} = \nabla^T f(\vec{x}') \vec{u}, \quad (9)$$

oraz z nierówność Schwartza

$$\nabla^T f(\vec{x}') \vec{u} \geq -\|\nabla^T f(\vec{x}')\| \cdot \|\vec{u}\| = -\|\nabla^T f(\vec{x}')\| = \min. \quad (10)$$

Należy wybrać wektor kierunkowy o postaci

$$\vec{u} = \frac{-\nabla f(\vec{x}')}{\|\nabla f(\vec{x}')\|} \quad (11)$$

aby wskazywał kierunek największego spadku, a pochodna kierunkowa mogła osiągnąć najmniejszą wartość.

$$\frac{dF(0)}{d\lambda} = -\nabla^T f(\vec{x}') \frac{\nabla f(\vec{x}')}{\|\nabla f(\vec{x}')\|} = \min \quad (12)$$

## 2 Cel zadania

Celem laboratorium było znalezienie minimum przy pomocy metody największego spadku w 2D funkcji:

$$f(\vec{r}) = f(x, y) = \frac{5}{2}(x^2 - y)^2 + (1 - x)^2, \quad (13)$$

zaczynając od przybliżenia  $\vec{r}_0$ :

$$\vec{r}_{i+1} = \vec{r}_i - h \cdot \nabla f(\vec{r})|_{\vec{r}=\vec{r}_i} \quad \text{gdzie } \nabla f(\vec{r}) = \left[ \frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right], \quad (14)$$

które było korygowane w kolejnych iteracjach. Składowe gradientu ze wzoru (14) obliczano numerycznie korzystając z faktu, iż


$$\frac{\partial f(\vec{r})}{\partial x} = \frac{f(\vec{r} + \Delta \vec{e}_x) - f(\vec{r} - \Delta \vec{e}_x)}{2\Delta} \quad (15)$$

$$\frac{\partial f(\vec{r})}{\partial y} = \frac{f(\vec{r} + \Delta \vec{e}_y) - f(\vec{r} - \Delta \vec{e}_y)}{2\Delta} \quad (16)$$


gdzie  $\vec{e}_x$  i  $\vec{e}_y$  są wektorami układu kartezjańskiego. Przyjęto następujące założenia:  $\Delta = 10^{-4}$ , punkt początkowy  $\vec{r}_0 = [-0.75, 1.75]$ , stała  $h = 0.01$ . Warunki stopu:  $\|\vec{r}_{i+1} - \vec{r}_i\|_2 < \epsilon$  dla  $\epsilon_1 = 10^{-2}$ ,  $\epsilon_2 = 10^{-3}$  Maksymalna liczba iteracji 1000, a  $x, y \in [-2, 2]$  z krokiem w obu kierunkach równym 0.02

### 3 Wyniki

Korzystając skryptu programu *Gnuplot* sporządzono wykresy dla obu przypadków. Dokładne minimum funkcji było jedno i wyniosło  $\vec{r}_{min} = [1, 1]$  (zaznaczone czarnym krzyżykiem). Na rysunkach znajdują się także kontur wartości funkcji  $f(x, y)$  oraz kolejne przybliżenia minimum.



Rysunek 1: Położenia kolejnych przybliżeń minimum funkcji  $f(x, y)$  w poszczególnych iteracjach dla  $\epsilon = 10^{-2}$ . Program wykonał 37 iteracji.



Rysunek 2: Położenia kolejnych przybliżeń minimum funkcji  $f(x, y)$  w poszczególnych iteracjach dla  $\epsilon = 10^{-3}$ . Program wykonał 1000 iteracji.

## 4 Wnioski

Wykresy dowodzą, iż ciężko jest wybrać trafne kryterium zbieżności. Dla pierwszego przypadku nie udało się osiągnąć minimum. Zmniejszając rząd zbieżności o jeden, zastosowanie znalazł drugi warunek stopu z uwagi na niekończące się oscylacje wokół poszukiwanego minimum. Potwierdziło to również teoretyczny kształt przebiegu dla funkcji z wydłużonym konturem. Duże znaczenie dla lepszej efektywności uzyskiwanych przybliżeń ma wartość  $h$ . Podczas laboratorium skoki nie były regulowane, co znalazło szczególne odbicie w punktach funkcji o niewielkim gradiencie, a w konsekwencji nie osiągnięto zbieżności. Metoda największego spadku może być mało wydajna, jeśli kontur wartości funkcji celu jest wydłużony.